

**Pengembangan *Named Entity Recognition* Berbasis
Fine-Tuning IndoBERT untuk Ekstraksi Data
di PT. Rafay Logistik**



SKRIPSI

Diajukan untuk memenuhi mata kuliah Kerja Praktik
pada Program Sarjana

ALIF HAIKAL

2022310051

**Program Studi Teknik Informatika
Fakultas Informatika dan Desain
Universitas Bina Insani**

Bekasi

2025

DAFTAR ISI

BAB I PENDAHULUAN	1
1.1. Latar Belakang Masalah.....	1
1.2. Identifikasi Masalah.....	3
1.3. Batasan Masalah.....	4
1.4. Perumusan Masalah	6
1.5. Tujuan dan Manfaat Penelitian	6
1. Tujuan Penelitian	6
2. Manfaat Penelitian.....	7
1.6. Sistematika Penulisan.....	8
BAB II TINJAUAN PUSTAKA	10
2.1. Tinjauan Pustaka.....	10
2.1.1. <i>Deep Learning</i>	10
2.1.2. <i>Deep Learning</i> untuk <i>Natural Language Processing</i>	11
2.1.3. <i>Natural Language Processing</i> untuk <i>Ekstraksi Informasi</i>	12
2.1.4. <i>Arsitektur Transformer</i>	12
2.1.5. <i>Arsitektur Transformer</i> dalam <i>Pemahaman Teks</i>	15
2.1.6. <i>IndoBERT</i>	17
2.1.7. Pendekatan <i>Fine-Tuning</i> <i>InDoBERT</i> untuk <i>Ekstraksi Bahasa Alami</i>	19
2.1.8. <i>Named Entity Recognition (NER)</i>	21
2.1.9. <i>Semantic Similarity</i> dan <i>Sequence-Pair Classification</i>	22
2.1.10. <i>Deep Learning</i> dan Sistem Berbasis Aturan untuk <i>Standarisasi Output</i>	23
2.1.11. <i>Metrik Evaluasi Kinerja Model</i> pada <i>Pemrosesan Bahasa Alami</i>	23
2.1.12. <i>Data Preprocessing</i>	25
2.1.13. <i>Data Training</i>	26
2.1.14. <i>Data Augmentation</i>	27
2.1.15. <i>Python</i> sebagai <i>Bahasa Pemrograman Utama</i> untuk <i>Deep Learning</i>	27
2.2. Penelitian Terkait.....	28
BAB III METODOLOGI PENELITIAN	33
3.1. Kerangka Pemikiran.....	33
3.1.1. Teknik Pengumpulan Data	38
3.1.2. Observasi	38
3.1.3. Wawancara	39

3.1.4.	Studi Pustaka	39
3.2.	Metode Ai Yang Gunakan	40
3.2.1.	Arsitektur IndoBERT	40
3.3.	Model Pengembangan Sistem.....	42
BAB III HASIL DAN PEMBAHASAN		47
4.1.	Tinjauan Perusahaan	47
4.1.1.	Profil Perusahaan	47
4.1.2.	Struktur Perusahaan.....	47
4.2.	Analisis Kebutuhan Sistem	47
4.2.1.	Analisis Sistem Saat Ini	47
4.2.2.	Anallisis Kebutuhan Fungsional.....	48
4.2.3.	Analisis Kebutuhan Non Fungsional.....	48
4.3.	Perancangan dan Implementasi Sistem	48
4.3.1.	Deskripsi Sistem	48
4.3.2.	Tahapan Pengembangan Model AI	48
4.3.3.	Implementasi Perangkat Lunak.....	48
4.4.	Pengujian Sistem	48
4.4.1.	Pengujian Fungsional	48
4.4.2.	Uji Coba Pengguna	48

BAB I

PENDAHULUAN

1.1. Latar Belakang Masalah

Seiring pesatnya perkembangan industri logistik, efisiensi pengelolaan informasi menjadi kunci utama dalam menjaga kelancaran rantai pasok dan daya saing perusahaan. PT. Rafay Logistik, sebagai entitas yang bergerak dalam jasa transportasi, memanfaatkan platform komunikasi digital seperti WhatsApp untuk memfasilitasi koordinasi pesanan secara *real-time*. Namun, penggunaan pesan teks tidak terstruktur ini membawa tantangan tersendiri dalam proses dokumentasi dan administrasi *internal* [Maharani et al., 2025]. Ketergantungan pada komunikasi manual yang intensif mulai menunjukkan celah kerentanan seiring dengan meningkatnya kompleksitas transaksi operasional, yang menuntut akurasi data tinggi di tengah *volume* pekerjaan yang terus bertambah secara signifikan.

Masalah operasional berakar pada jumlah entri data secara manual mencapai ribuan *field* per bulan ditangani oleh dua orang admin, sehingga berisiko menyebabkan penumpukan pekerjaan. Dalam praktiknya, satu pesan mentah sering kali memuat instruksi untuk beberapa unit armada sekaligus dimana satu pesanan berisi beberapa unit akan menghasilkan beberapa baris data terpisah di Excel yang masing-masing membutuhkan pengisian delapan *field* informasi utama. Hal ini menyebabkan admin harus mengekstraksi dan memvalidasi hingga puluhan entri data dari satu pesan tunggal secara manual. Saat ini, dua staf admin mengelola ribuan entri per *field* setiap bulan.

Berdasarkan konfirmasi dari pemilik perusahaan terkait rencana ekspansi kerja sama bisnis di masa mendatang, peningkatan volume pesanan dipastikan akan segera melampaui jumlah rata-rata data operasional saat ini. Kondisi *unsustainable scalability* ini berisiko memicu kelelahan kognitif (*cognitive load*) yang dapat melumpuhkan akurasi operasional serta menghambat proses pengambilan keputusan manajerial,

Masalah selanjutnya adalah proses pencocokan dan entri ulang data susulan untuk melengkapi atau merevisi data sebelumnya ditangani secara manual sehingga berisiko memperlambat proses pembaruan informasi operasional. Dalam praktiknya, instruksi pelengkapan data susulan (*refill*) pada data yang tidak lengkap sebelumnya, maupun revisi krusial seperti perubahan identitas pengemudi atau nomor kendaraan sering kali diterima melalui pesan singkat tanpa disertai rujukan identitas pesanan induk yang eksplisit. Hal tersebut sekaligus menyingkap kelemahan mendasar sistem pencatatan konvensional dalam menangani ambiguitas relasi data, yang diprediksi akan menjadi hambatan besar dalam menghadapi lonjakan volume data di masa mendatang.

Menghadapi tantangan ganda berupa lonjakan eksponensial beban entri data manual dan ambiguitas pada data susulan, PT. Rafay Logistik memerlukan transformasi sistemik yang melampaui kemampuan metode konvensional. Pendekatan berbasis aturan murni tidak mampu menangani variasi bahasa alami yang sangat dinamis pada platform WhatsApp. Oleh karenanya, penelitian ini mengusulkan pendekatan *hybrid* berbasis arsitektur InDoBERT yang mengintegrasikan dua komponen spesifik [Prasetyo and Nur, 2024], Pertama,

komponen *Named Entity Recognition* (NER) yang berfungsi pada level token untuk mengekstraksi variasi jenis atribut pesanan dari pesan WhatsApp yang tidak terstruktur, kedua, komponen *semantic similarity matching* melalui *sequence-pair classification* yang bekerja pada level kalimat untuk menyelesaikan ambiguitas pada pesan revisi dan *refill*.

Pendekatan pemilihan dua model terpisah untuk dua tugas yang *fundamentally* berbeda ini didasarkan pada prinsip *specialization* setiap model dirancang sesuai karakteristik masalahnya untuk mencapai akurasi optimal. Lapisan *rule-based post-processing* kemudian menyempurnakan hasil melalui standardisasi format dan validasi data. Integrasi strategis ini diharapkan dapat mengurangi waktu pemrosesan input data per pesanan, meningkatkan akurasi ekstraksi data, dan memposisikan infrastruktur perusahaan menghadapi pertumbuhan bisnis yang diproyeksikan akan meningkat di masa mendatang.

1.2. Identifikasi Masalah

Berdasarkan uraian latar belakang, beberapa masalah yang dapat diidentifikasi adalah sebagai berikut:

1. Jumlah entri data secara manual mencapai ribuan *field* per bulan ditangani oleh dua orang admin, sehingga berisiko menyebabkan penumpukan pekerjaan.
2. Pencocokan dan entri ulang data susulan untuk melengkapi atau merevisi data sebelumnya ditangani secara manual sehingga berisiko memperlambat proses pembaruan informasi operasional.

1.3. Batasan Masalah

Berdasarkan identifikasi masalah yang telah dipaparkan, laporan ini dibatasi pada hal-hal berikut:

1. Sumber data dibatasi secara eksklusif pada teks obrolan WhatsApp operasional PT Rafay Logistik, integrasi data dari ekosistem lain seperti Surat Perintah Kerja (SPK), sistem alokasi armada, pelacakan GPS, *pricing engine*, dan sistem eksternal lainnya tidak termasuk dalam objek ekstraksi.
2. Cakupan analisis linguistik secara spesifik difokuskan pada pesan pembentukan pesanan baru, revisi, dan pelengkapan data (*refill*).
3. Ekstraksi entitas dibatasi pada atribut operasional inti (meliputi tanggal *Request Order* (RO), tanggal muat, jumlah dan jenis unit, lokasi asal dan tujuan, identitas pengemudi, nomor polisi, serta nomor kontak.
4. Sistem tidak dirancang untuk melakukan imputasi data otomatis terhadap parameter yang secara faktual tidak ada dalam pesan, field yang hilang atau tidak lengkap akan direpresentasikan secara parsial.
5. Pemodelan kecerdasan buatan bersifat sangat spesifik untuk domain linguistik (*domain-specific*) PT Rafay Logistik. Tingkat generalisasi akurasi pada perusahaan logistik lain tidak dijamin tanpa adanya proses pelatihan ulang (*re-training*) dan penyesuaian parameter.
6. Pendekatan komputasi dibatasi pada penerapan algoritma transfer learning melalui tahapan *fine-tuning* pada arsitektur IndoBERT, dan tidak mencakup pengembangan arsitektur foundation model dari nol.

7. Komponen *post-processing* untuk normalisasi berbasis aturan (*rule-based*) disusun secara manual berdasarkan observasi pola data historis seperti tipografi label, variasi penulisan nomor kontak, dan format waktu bukan melalui mekanisme *automatic rule learning*.
8. Purwarupa diposisikan murni sebagai sistem pendukung operasional dengan pendekatan *human-in-the-loop*, di mana validasi akhir dan pengambilan keputusan mutlak tetap berada di bawah otoritas *administrator*.
9. Cakupan penelitian belum menyentuh implementasi operasional real-time, integrasi dengan *Application Programming Interface* (API) WhatsApp *Business*, orkestrasi *message queue*, maupun pemenuhan *Service Level Agreement* (SLA) operasional tidak dilakukan.
10. Fokus pengujian berada pada validasi ketepatan ekstraksi komputasi, sehingga pengujian tingkat produksi seperti *load/stress testing*, penguatan keamanan (*security hardening*), dan penerapan *reliability engineering* tidak termasuk dalam batasan penelitian ini.
11. Evaluasi kinerja algoritma difokuskan pada pencapaian standar metrik ekstraksi *Natural Language Processing* (NLP) meliputi Precision, Recall, F1-Score, dan ketepatan matching. Pengukuran tersebut tidak melibatkan analisis metrik bisnis seperti efisiensi beban biaya atau *Return on Investment* (ROI).
12. Pengujian dan validasi pemodelan menggunakan data historis internal yang dikumpulkan pada periode terkontrol (Oktober 2025 - Maret

2026), sehingga hasil inferensi model belum sepenuhnya merepresentasikan fluktuasi anomali variasi musiman multi-tahun.

1.4. Perumusan Masalah

Berdasarkan identifikasi masalah yang telah dipaparkan, laporan ini dibatasi pada hal-hal berikut:

1. Bagaimana menerapkan pendekatan *Named Entity Recognition* menggunakan model *fine-tuning* IndoBERT untuk menangani jumlah entri data secara manual yang mencapai ribuan *field* per bulan oleh dua orang admin, yang berisiko menyebabkan penumpukan pekerjaan?
2. Bagaimana menerapkan pendekatan *sequence-pair classification* menggunakan model *fine-tuning* IndoBERT untuk menangani pencocokan dan entri ulang data susulan (guna melengkapi atau merevisi data sebelumnya) yang saat ini ditangani secara manual, sehingga berisiko memperlambat proses pembaruan informasi operasional?

1.5. Tujuan dan Manfaat Penelitian

Berdasarkan perumusan masalah yang telah dipaparkan, penelitian ini memiliki tujuan dan manfaat sebagai berikut:

1. Tujuan Penelitian
 - a. Mengembangkan pendekatan *Named Entity Recognition* menggunakan model *fine-tuning* IndoBERT untuk menangani entri data manual berjumlah ribuan *field* per bulan, guna memitigasi secara signifikan risiko penumpukan pekerjaan yang dihadapi oleh staf administrasi.

- b. Mengembangkan pendekatan *sequence-pair classification* menggunakan model *fine-tuning* IndoBERT untuk menangani proses pencocokan dan entri ulang data susulan, guna meminimalisasi risiko keterlambatan pada proses pembaruan informasi operasional perusahaan.

2. Manfaat Penelitian

a. Manfaat Teoritis

- 1. Memberikan kontribusi bagi pengembangan studi mengenai implementasi *Natural Language Processing* (NLP), khususnya pada pemanfaatan arsitektur *transformer* InDoBERT untuk pemrosesan teks berderau (*noisy text*) di ranah operasional logistik.
- 2. Menjadi referensi atau rujukan bagi penelitian selanjutnya yang berkaitan dengan optimalisasi pendekatan *hybrid* dalam menyelesaikan masalah ambiguitas semantik dan ekstraksi entitas tanpa harus melatih model bahasa dari awal (*transfer learning*).

b. Manfaat Praktis

- 1. Memangkas secara signifikan waktu yang dibutuhkan staf admin untuk mendekode dan memvalidasi puluhan *field* entri data dari pesan pesanan multi-unit secara manual.
- 2. Mengurangi risiko kesalahan penempatan informasi (*merge conflicts*) pada saat proses pencatatan revisi susulan melalui sistem pencocokan konteks secara otomatis yang memberikan rekomendasi pesanan secara akurat.

1.6. Sistematika Penulisan

Untuk memberikan gambaran yang menyeluruh, penelitian ini diuraikan ke dalam lima bab dengan sistematika sebagai berikut:

BAB I PENDAHULUAN

Bab pendahuluan ini merumuskan arah kerja penelitian. Alurnya dimulai dari latar belakang masalah. Kemudian dijelaskan juga batasan masalah. Tujuannya agar pengembangan algoritma tetap relevan dengan rumusan masalah utama. selanjutnya memaparkan manfaat konkret dari penelitian, lalu ditutup dengan rincian sistematika penulisan sebagai kerangka baca.

BAB II TINJAUAN PUSTAKA

Bab ini menguraikan tinjauan pustaka dan landasan teori teknis yang mendasari sistem pengolahan teks tidak terstruktur. Fokus pembahasan mencakup *Deep Learning*, *Natural Language Processing* (NLP), pemodelan *Transformer* menggunakan InDoBERT, ekstraksi entitas (*NER*), serta klasifikasi kesamaan semantik. Selain teori fundamental, bab ini juga menyertakan kajian terhadap penelitian-penelitian terdahulu yang sejalan.

BAB III METODOLOGI PENELITIAN

Alur kerja penelitian dibahas secara menyeluruh di bab ini. Tujuannya mencakup membuat kerangka penelitian, mengumpulkan data teks operasional, dan menentukan teknik pengembangan sistem. Bab ini juga membahas arsitektur model

kecerdasan buatan yang digunakan. Pembaca dapat mengikuti seluruh proses teknis yang terlibat dalam pembuatan sistem ekstraksi informasi logistik ini karena setiap tahapan diuraikan secara khusus.

BAB IV HASIL DAN PEMBAHASAN

Bab sebelumnya merancang model kecerdasan buatan, dan bab ini membahas tahapan implementasi dan pengujiannya. Fokus diskusi adalah arsitektur dan proses *fine-tuning* algoritma InDoBERT untuk menyelesaikan dua tugas utama dalam pencocokan *semantic*, pencocokan nama entitas (*NER*) dan klasifikasi *pair* urutan. Bab ini juga membahas hasil evaluasi performa model menggunakan metrik pengujian standar. Selanjutnya, ada analisis mendalam tentang kemampuan algoritma untuk memproses dan mengekstraksi data logistik tidak terstruktur dengan benar.

BAB V SIMPULAN DAN SARAN

Hasil evaluasi model diberikan dalam bab penutup ini. Sebagai kesimpulan, bagian ini menjelaskan seberapa baik implementasi arsitektur InDoBERT menangani masalah ekstraksi data logistik. Selanjutnya, perhatian beralih ke bagian saran. Di sini, batasan teknis algoritma ini diuraikan menjadi saran yang dapat diukur untuk pengembangan penelitian di masa mendatang.

BAB II

TINJAUAN PUSTAKA

2.1. Tinjauan Pustaka

“Secara umum, tinjauan pustaka adalah metode yang digunakan sebagai dasar untuk menciptakan karya ilmiah. Proses ini terdiri dari langkah-langkah terstruktur yang dimulai dari pengumpulan data, membaca, dan mencatat informasi dari berbagai sumber yang dapat diandalkan” [Wesley and Gunawan, 2024]. “Dalam praktiknya, teknik tinjauan ini digunakan secara sistematis untuk memetakan dan menemukan apa yang sudah diketahui tentang penelitian sebelumnya tentang fenomena atau subjek tertentu” [Sepriadi et al., 2025]. Selanjutnya, untuk memudahkan percakapan tentang hasil penelitian, data yang dikumpul diproses dan dianalisis. Tujuan utamanya adalah untuk membuat kesimpulan mendalam dengan menggabungkan berbagai informasi literatur tersebut.

2.1.1. *Deep Learning*

Salah satu jenis *Machine Learning* yang unik adalah *Deep Learning*. “Ini memanfaatkan arsitektur jaringan saraf tiruan berlapis, juga dikenal sebagai lapisan tersembunyi, untuk otomatis mempelajari dan mengekstraksi pola kompleks dari data berskala besar” [Adrianto, 2021]. Secara historis, gagasan dasar untuk meniru cara kerja neuron otak manusia ini telah digagas sejak pertengahan abad ke-20. Namun, berkat ketersediaan big data dan peningkatan daya komputasi modern pada tahun 2010-an, gagasan ini mencapai puncaknya. “Dengan kemajuan ini, kemampuan *Deep Learning* untuk memproses

representasi data secara otomatis telah terbukti mampu melampaui arsitektur pembelajar mesin tradisional dalam menangani masalah komputasi yang lebih kompleks seperti pemrosesan bahasa alami” [Hasanah, 2021].

Paradigma ini menjadi landasan teoretis yang sangat relevan untuk memecahkan masalah penelitian ini karena fakta bahwa *Deep Learning* memiliki keunggulan dalam mengekstraksi pola hierarkis yang rumit. Ini adalah metode penting untuk mengurai teks operasional yang sarat ambiguitas dan tidak terstruktur karena kemampuan komputasinya untuk memproses bahasa alami. Akibatnya, arsitektur *Deep Learning* digunakan sebagai kerangka utama untuk memfasilitasi pengekstraksian informasi kompleks secara otomatis. Ini juga memungkinkan untuk melampaui batasan analitik dari metode konvensional.

2.1.2. *Deep Learning* untuk *Natural Language Processing*

“Penguraian kata dalam *Natural Language Processing (NLP)*, seringkali menghadapi masalah saat melakukan tugas ekstraksi informasi. Ini disebabkan oleh fakta bahwa model sering mengalami kesulitan untuk menginterpretasikan makna dari data teks yang bersifat informal” [Fathur et al., 2024]. “Oleh karenanya pendekatan *Deep Learning* digunakan untuk melatih model agar lebih akurat mengenali dan memahami arti leksikal data agar dapat memahami semantik dan leksikal yang mendalam” [Dyah et al., 2026]. Menggabungkan *Deep Learning* ke dalam proses *Natural Language Processing (NLP)* merupakan kemajuan besar dalam mengotomatisasi ekstraksi pengetahuan karena kemampuan adaptasi semantik yang mendalam. Metode ini melampaui

keterbatasan metode berbasis aturan konvensional dan mampu menggambarkan hubungan antar-kata dari data teks yang rumit dan tidak terstruktur.


2.1.3. *Natural Language Processing untuk Ekstraksi Informasi*

Salah satu cabang dari kecerdasan buatan yang disebut *Natural Language Processing* (NLP) berfokus pada kemampuan komputer untuk memahami, mengolah, dan menganalisis bahasa manusia. “NLP dapat digunakan untuk mengekstraksi informasi dari data teks yang biasanya tidak terstruktur, seperti data dari percakapan digital” [Fathur et al., 2024]. “Model NLP telah terbukti sangat efektif dalam menganalisis dan memahami representasi konteks teks secara menyeluruh untuk mengklasifikasikan informasi ke dalam rujukan data yang tepat” [Dan et al., 2025]. Dengan kemampuan ini, proses pengolahan bahasa natural sangat penting untuk mengubah teks mentah yang rumit menjadi format data sistematis yang siap untuk pengolahan lanjutan.

2.1.4. *Arsitektur Transformer*

“Arsitektur Transformer adalah inovasi *Deep Learning* yang diluncurkan pada tahun 2017 dan telah mengubah pemrosesan bahasa alami dengan mengekstraksi representasi semantik secara otomatis” [Syazal and Yulianti, 2025]. Secara konseptual, model ini digunakan untuk mengatasi kelemahan utama dari arsitektur sebelumnya, seperti *RNN* dan *LSTM*, yang rentan mengalami masalah dengan mempertahankan informasi konteks pada urutan teks yang panjang. “Keunggulan utama dari arsitektur ini adalah pemanfaatan mekanisme *Self-Attention*, yang memungkinkan untuk mengidentifikasi

hubungan antar-kata yang kompleks di dalam teks secara akurat” [Hanif et al., 2026].



Sumber: [Vaswani, 2023].


Gambar II.1.

Arsitektur Dasar Transformer.

Gambar II.1 menunjukkan arsitektur dasar *Transformer* yang terdiri dari dua bagian utama. “Blok *Encoder* terletak di sebelah kiri dan blok *Decoder* terletak di sebelah kanan yang bekerja dengan menerima input dan mengubahnya menjadi representasi matematis yang kaya akan konteks melalui lapisan *Multi-Head Attention* dan *Feed Forward*”. Blok *Encoder* bertanggung jawab untuk mendapatkan pemahaman teks yang lebih baik, oleh karenanya pemodelan yang

digunakan hanya akan menggunakan struktur blok *Encoder* karena penelitian ini berfokus pada penggunaan model bahasa representasi dua arah seperti BERT dan IndoBERT.

Mekanisme *Attention* merupakan dasar matematis yang mendasari kemampuan blok *Encoder* tersebut. Mekanisme ini digambarkan secara khusus melalui fungsi *Scaled Dot-Product* dan dapat digunakan secara paralel sebagai *Multi-Head Attention*, seperti yang ditunjukkan pada Gambar II.2.



. Sumber: [Vaswani, 2023].

Gambar II.2.

Mekanisme *Scaled Dot-Product Attention* dan *Multi-Head Attention*.

Gambar II.2 menunjukkan mekanisme komputasi inti *Transformer*, yang secara struktural dibagi menjadi dua fungsi operasional, *Scaled Dot-Product Attention* dan *Multi-Head Attention*. Komponen *Scaled Dot-Product Attention* beroperasi secara matematis dengan memproyeksikan data ke dalam tiga vektor utama, yakni *Query* (Q), *Key* (K), dan *Value* (V). “Dalam proses ini, skor atensi dihitung dengan menggunakan operasi perkalian *dot-product* antara Q dan K,


dan kemudian dinormalisasi” [Lin et al., 2021]. Dengan membagi dimensi representasi menjadi beberapa kepala komputasi yang bekerja secara independen dan paralel, arsitektur ini memperluasnya menjadi *Multi-Head Attention*. Hal ini dilakukan daripada melakukan komputasi tersebut secara tunggal. “Penggabungan dari seluruh kepala pemrosesan ini menunjukkan bahwa model dapat menangkap ambiguitas semantik dan dependensi linguistik dari berbagai sudut pandang teks dengan lebih akurat” [Kalyan et al., 2021].

Arsitektur ini dianggap sangat relevan sebagai kerangka landasan dalam pemecahan masalah karena keunggulan mekanisme *Self-Attention* dalam menangkap konteks kalimat secara bersamaan. Sangat cocok untuk mengurai pesan operasional yang tidak terstruktur tanpa kehilangan informasi penting karena dapat memproses banyak input teks yang kompleks sekaligus. Akibatnya, prinsip arsitektural ini digunakan untuk memastikan bahwa setiap komponen data diekstraksi dengan tingkat efisiensi dan presisi yang jauh melampaui pemodelan tradisional.

2.1.5. Arsitektur Transformer dalam Pemahaman Teks

Arsitektur *Transformer* pada dasarnya adalah arsitektur *Deep Learning* yang dirancang untuk menangani data berurutan, mirip dengan teks dalam pemrosesan bahasa alami (*NLP*). “Mekanisme *self-attention* adalah keunggulan utama *Transformer* yang memungkinkan model dapat melihat semua kata dalam kalimat secara bersamaan, dan kemudian menghitung kata mana yang memiliki hubungan paling signifikan satu sama lain” [Ezer et al., 2026]. “*Self-attention* membuat *Transformer* memahami makna kalimat secara lebih cepat,

konsisten, dan mendalam. Ini berbeda dengan model lama yang mengharuskan mereka membaca teks secara berurutan dari kiri ke kanan” [Wesley and Gunawan, 2024].



Sumber: [Vaswani, 2023].

Gambar II.3.


Visualisasi Mekanisme *Self-Attention* pada Pemrosesan Kalimat.

Gambar II.3 dan menunjukkan mekanisme penghitungan bobot hubungan antar-kata secara visual. Gambar ini menunjukkan bagaimana sebuah kata yang sedang diproses, seperti kata "making", memetakan garis perhatian ke semua kata lain dalam kalimat yang sama. Ketebalan atau kepekatan warna garis menunjukkan tingkat signifikansi kontekstual antara kedua kata tersebut. Sebagai contoh, model beralih dari kata "making" ke kata "more" dan "difficult". Fenomena ini menunjukkan bahwa *Transformer* dapat menangkap dependensi frasa secara langsung tanpa memproses kalimat secara keseluruhan. Ini berlaku meskipun posisi kata-kata berjauhan. Oleh karena itu, terbukti bahwa arsitektur Transformer dapat menghasilkan representasi konteks yang jauh lebih luas dan efisien.

Arsitektur *Transformer* telah diadopsi secara masif berkat kemampuannya yang luar biasa dalam menganalisis struktur data teks. Secara konseptual, penerapan arsitektur ini dibangun atas dua tahapan utama, yakni *pre-training* dan *fine-tuning*. “Tahap *pre-training* menginisialisasi bobot model menggunakan kumpulan teks tanpa label untuk membentuk pemahaman awal. Selanjutnya, model memasuki fase *fine-tuning* untuk diadaptasi menggunakan *dataset* spesifik berlabel.” [Awalina et al., 2022]. Dibandingkan dengan melatih model secara fundamental dari awal, pendekatan *fine-tuning* kerap menjadi prioritas utama karena dinilai lebih efisien secara komputasi dan waktu, namun tetap mampu memberikan hasil prediksi yang akurat.

2.1.6. IndoBERT

IndoBERT adalah model bahasa monolingual yang telah dilatih sebelumnya berbasis arsitektur *Transformer* yang dirancang khusus untuk memproses bahasa Indonesia untuk kebutuhan mengatasi masalah linguistik lokal yang rumit, seperti keanekaragaman bahasa. Kebutuhan tersebut mendorong pembuatan model dengan menggunakan korpus besar yang berasal dari berita dan media sosial. “Pelatihan intensif telah menjadikan IndoBERT standar utama untuk berbagai tugas pemrosesan bahasa alami (*NLP*) berbahasa Indonesia” [Ishak, 2026].




Sumber: [Han et al., 2021].

Gambar II.4.

Perbandingan Arsitektur Dasar *Transformer*, GPT, dan BERT.

Evolusi arsitektur tersebut dapat diamati dengan jelas pada Gambar II.4. Berbeda dengan *Transformer* konvensional (kiri) yang menggunakan format *Encoder-Decoder*, arsitektur BERT yang menjadi fondasi murni dari IndoBERT terlihat pada bagian paling kanan gambar, di mana model ini secara eksklusif hanya dibangun di atas tumpukan lapisan *Encoder* [Han et al., 2021]. Gambar tersebut juga menampilkan arsitektur *Generative Pre-Training Transformer (GPT)* di bagian tengah yang berfokus pada lapisan *Decoder*. Jika *GPT* secara fundamental dirancang optimal untuk tugas penalaran generatif teks secara satu arah, IndoBERT dengan struktur *Encoder* nya memiliki pendekatan komputasi yang difokuskan pada pemahaman konteks teks secara utuh.



Sumber: [Kenton et al., 2019].

Gambar II.5.


Pemecahan *Subword* dengan *Tokenizer WordPiece* dan Pembentukan *Embedding*

Kontekstual.

Secara konseptual, IndoBERT beroperasi dengan menghasilkan *embedding* kontekstual, di mana representasi makna setiap kata dihitung berdasarkan kata-kata lain di sekitarnya. Kapabilitas ini memberikan model kemampuan superior dalam membedakan kata bermakna ganda dan menangkap dependensi kalimat jarak jauh. “Selain itu, model ini memanfaatkan mekanisme *tokenizer WordPiece* untuk memecah teks menjadi unit *subword*” [Ignasius et al., 2025]. Metode ini telah terbukti sangat efektif dalam mempertahankan detail informasi morfologis yang kaya akan variasi imbuhan dan selalu berubah dalam bahasa Indonesia. Model tetap mampu menggambarkan representasi semantik meskipun menghadapi kosakata yang belum pernah dilihat sebelumnya melalui pemecahan kata kompleks menjadi komponen dasar penyusunnya. Oleh karena itu, strategi tokenisasi ini dapat menangani masalah kata yang tidak dikenali (*out-of-vocabulary*), yang memastikan stabilitas pemrosesan teks secara keseluruhan.

2.1.7. Pendekatan *Fine-Tuning* InDoBERT untuk Ekstraksi Bahasa Alami

“IndoBERT memiliki kemampuan untuk menghasilkan representasi numerik yang sangat lengkap pada tahap fiturisasi data teks, sebagai model yang telah dilatih secara *Pre-Trained monolingual* yang dilatih menggunakan lebih dari 220 juta kosakata bahasa Indonesia” [Annisa et al., 2024]. Namun, melalui proses penyesuaian, representasi dasar baru ini dapat digunakan secara maksimal dan tepat pada target pemecahan masalah. “Kemampuan untuk membuat embedding kontekstual yang bergantung pada tokenisasi tingkat *subword* (*WordPiece*) telah terbukti meningkatkan keunggulan adaptasi arsitektur ini secara signifikan selama tahapan spesialisasi ini” [Ignasius et al., 2025].



Sumber: [Kenton et al., 2019].

Gambar II.6.

Ilustrasi Prosedur Keseluruhan Tahap *Pre-training* dan *Fine-tuning* pada Arsitektur IndoBERT.

Gambar II.6 menunjukkan perbedaan struktural dan prosedural antara *Pre-Training* dan *Fine-Tuning*. Proses *Pre-Training*, yang terletak di panel kiri, menghasilkan representasi bahasa dasar melalui pemrosesan korpus teks tanpa label (*Unlabeled Sentence*) melalui tugas prediksi probabilitas kata yang

disembunyikan (*Mask LM*) dan korelasi logis antar-kalimat (*NSP*). Dalam inisialisasi *Fine-Tuning*, "lapisan output teratas model diubah dan dilatih ulang menggunakan dataset tertentu dengan tujuan menyelesaikan masalah komputasional" [Han et al., 2021]. bobot representasi tahap *Pre-Training* ditransfer ke tahap *Fine-Tuning*. Tahapan spesialisasi ini sangat penting bagi IndoBERT karena, dalam menangani polisemi dan batasan entitas, "metode adaptif ini secara signifikan mengungguli metode penerapan embedding statis konvensional" [Kalyan et al., 2021]. Oleh karena itu, dapat disimpulkan bahwa ketajaman model dalam mengurai kompleksitas morfologis bahasa Indonesia sangat bergantung pada pembaruan bobot di tahap *Fine-Tuning* ini. Ini secara fundamental mengubah pengetahuan bahasa umum menjadi alat yang tepat untuk memecahkan masalah.

2.1.8. *Named Entity Recognition (NER)*

Proses pemrosesan bahasa alami (*NLP*) yang sangat penting adalah *Named Entity Recognition (NER)*. "*NER* di dalam teks dan kemudian membaginya ke dalam kategori tertentu yang telah ditentukan sebelumnya" [Annisa et al., 2024]. "*Sistem NER* konvensional yang bergantung pada aturan manual atau model statistik sering mengalami masalah. Karena terminologi teks yang sangat berubah dan ketergantungan konteks jarak jauh pada data nyata" [Ignasius et al., 2025]. Akibatnya, pendekatan *NER* kontemporer sangat bergantung pada arsitektur *Deep Learning* yang sangat baik untuk mengatasi variasi leksikal dan meningkatkan kemampuan model untuk mengidentifikasi batasan kata yang ambigu. Kajian tersebut menunjukkan bahwa penggunaan *NER* saat ini tidak

lagi terbatas pada pencocokan kata baku. Sebaliknya, itu berfungsi sebagai dasar analitis cerdas yang sangat penting untuk mengubah cerita teks mentah menjadi representasi data terstruktur yang penuh dengan makna semantik.

2.1.9. *Semantic Similarity* dan *Sequence-Pair Classification*

Dalam domain pemrosesan bahasa alami, evaluasi kesamaan teks telah berkembang melampaui korespondensi leksikal belaka, sebaliknya beralih ke evaluasi konseptual yang lebih bernuansa kedekatan semantik. Pendekatan yang menggunakan arsitektur *Transformer*, seperti IndoBERT, menjadi sangat signifikan karena memanfaatkan mekanisme *self-attention* untuk menilai kesamaan semantik dalam pasangan kalimat lengkap. Melalui penerapan mekanisme ini, “model mampu mengkategorikan dua teks yang menunjukkan tingkat kesamaan yang substansif, bahkan ketika menggunakan pilihan leksikal yang berbeda, asalkan kedua teks menyampaikan makna kontekstual yang sama” [Pradani et al., 2023]. “Keandalan arsitektur ini semakin terbukti melalui pemrosesan pasangan kalimat (*sequence-pair*) menggunakan IndoBERT, yang secara signifikan mampu meningkatkan akurasi pengukuran relasi logis dan keterkaitan semantik pada teks berbahasa Indonesia” [Tandi, 2025].

Karakteristik fungsional ini menunjukkan keunggulan utama arsitektur *Transformer* dibandingkan dengan metode pencocokan fitur statis konvensional, yang biasanya terbatas pada pemetaan frekuensi kemunculan kata tanpa mempertimbangkan hubungan semantik laten yang mendasarinya. Model ini dapat melampaui analisis berbasis leksikal untuk mengidentifikasi hubungan antar elemen dalam kalimat secara lebih akurat.

2.1.10. *Deep Learning* dan Sistem Berbasis Aturan untuk Standarisasi *Output*

Pendekatan hibrida yang secara konseptual bekerja dengan "menggabungkan metode Sistem Berbasis Aturan dan *Deep Learning* untuk memanfaatkan keunggulan dari masing-masing metode tersebut dalam menciptakan sistem baru yang lebih tangguh" [Yanti et al., 2021]. Metode tersebut menjadi dasar penting dalam arsitektur ekstraksi informasi modern untuk mencapai presisi sekaligus standarisasi *output* yang tinggi. Karena arsitektur komputasi yang murni hanya bergantung pada aturan manual dan "memiliki keterbatasan dalam menangani data yang kompleks dan variasi informasi yang luas, serta membutuhkan waktu pembuatan yang lama" [Hasmin et al., 2024].

Berdasarkan rasionalisasi ini, dapat disimpulkan bahwa penggabungan kedua sistem ini menghasilkan sinergi komplementer yang sangat penting. Arsitektur *Deep Learning* berfungsi sebagai mesin analitis cerdas untuk membedah ambiguitas dan mengekstrak variasi dari data teks secara otomatis, sementara mekanisme berbasis aturan berfungsi sebagai filter validasi akhir (*post-processing*) untuk memastikan bahwa struktur output yang dihasilkan tetap konsisten, tepat, dan terstandarisasi.

2.1.11. Metrik Evaluasi Kinerja Model pada Pemrosesan Bahasa Alami

Dalam arsitektur *Deep Learning*, pengukuran kinerja model tidak dapat didasarkan pada akurasi mutlak sebagai satu-satunya parameter penilaian. Ini terutama berlaku dalam bidang pemrosesan bahasa alami (*NLP*), di mana struktur teks dengan distribusi entitas tidak seimbang sering dihadapi. Dalam

konteks ini, "pengujian performa model klasifikasi teks secara komprehensif mutlak membutuhkan evaluasi *Confusion Matrix* yang didasarkan pada nilai *Accuracy* dan *F1-Score* untuk mengukur kinerjanya secara objektif" [Supono, 2021]. *True Positive (TP)*, *True Negative (TN)*, *False Positive (FP)*, dan *False Negative (FN)* adalah empat komponen dasar *Matrix Confusion* Parameter yang menunjukkan hubungan antara prediksi model dan label aktual. Berdasarkan elemen ini, evaluasi kinerja global dibagi menjadi empat metrik utama, masing-masing dengan penjabaran matematis sebagai berikut [Tharwat, 2026]:

- A. *Accuracy*: adalah rasio persentase dari prediksi model yang benar secara keseluruhan terhadap jumlah data yang ada.

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN}$$

- B. *Precision*: Rasio ketepatan prediksi positif model dibandingkan dengan seluruh hasil yang diprediksi positif digunakan untuk menentukan seberapa sedikit model melakukan salah tebak (*false positive*).

$$Precision = \frac{TP}{TP+FP}$$

- C. *Recall*: rasio keberhasilan model dalam menemukan kembali seluruh entitas positif aktual. Ini digunakan untuk menghitung seberapa sedikit data yang dilewatkan model (*false negative*).

$$Recall = \frac{TP}{TP+FN}$$

- D. *F1-Score*: Nilai rata-rata harmonik, atau nilai rata-rata harmonik, yang menggabungkan *Precision* dan *Recall* menjadi satu parameter evaluasi yang luas.

$$F1-Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Keempat metode pengukuran di atas Sangat penting untuk tugas ekstraksi informasi khusus karena "penggunaan metrik *Accuracy*, *Precision*, *Recall*, dan *F1-Score* secara bersamaan terbukti menjadi standar evaluasi komprehensif untuk mengukur seberapa baik model mengenali batasan dan makna entitas teks" [Yanti et al., 2021].

Berdasarkan dasar komputasi tersebut, *F1-Score* adalah indikator pengukuran yang paling penting di seluruh dunia. Jika Anda menggunakan sistem ekstraksi informasi logistik Anda, nilai *F1-Score* yang tinggi menunjukkan bahwa arsitektur komputasi Anda tidak hanya tepat dalam mengekstrak entitas berbagai unit, tetapi juga konsisten dan tidak mungkin melewatkan informasi penting dari pesan WhatsApp yang kotor dan tidak terstruktur.

2.1.12. Data Preprocessing

Data *preprocessing* dalam arsitektur *Deep Learning* sangat penting untuk mengubah teks operasional mentah menjadi struktur komputasi yang optimal. Ketidaksesuaian linguistik pada data tekstual sangat mengganggu kinerja, di mana "pengurangan tingkat noise melalui prapemrosesan teks terbukti secara signifikan meningkatkan kemampuan ekstraksi fitur pada model bahasa" [Sharou et al., 2021]. Selain itu, kualitas data ini sangat penting untuk kemajuan komputasi karena "kombinasi metode prapemrosesan terbukti menjadi pendekatan paling efektif yang secara signifikan meningkatkan hasil klasifikasi teks" [Kunilovskaya, 2021]. Oleh karena itu, implementasi prapemrosesan teks

yang tepat dan sistematis adalah dasar arsitektur IndoBERT untuk memaksimalkan kinerja dalam tugas pengenalan nama entitas (*NER*) dan klasifikasi pasangan kalimat (*Semantic Similarity*). Hal ini penting untuk menghilangkan ambiguitas semantik dari pesan order logistik operasional yang penuh dengan format informal, singkatan, dan struktur yang tidak terstruktur.

2.1.13. Data Training

Kualitas dan spesifisitas dataset pelatihan dalam arsitektur *Deep Learning* adalah faktor paling penting dalam menjembatani pengetahuan bahasa umum ke dalam pemahaman domain yang sempit. Meskipun model pra-latih menawarkan representasi bahasa yang luas, "prosedur *Fine-Tuning* tidak dapat menangkap pengetahuan yang cukup dari berbagai sumber data apabila tidak disertai dengan strategi yang berorientasi langsung pada target" [Jiang et al., 2021]. Selain itu, "tahap *Fine-Tuning* final yang dieksekusi di atas sekumpulan data berlabel kuat terbukti secara krusial memecahkan informasi yang tidak sesuai dengan tujuan" [Zhang et al., 2021].

Oleh karena itu, dapat disimpulkan bahwa data pelatihan harus dibuat dalam bentuk korpus pesanan logistik yang dianotasi secara manual dengan tepat. Tanpa landasan data latih berlabel kuat ini, arsitektur IndoBERT tidak akan dapat beradaptasi dengan baik untuk mengekstraksi entitas target (*Named Entity Recognition*) dan memvalidasi kesamaan makna teks (*Semantic Similarity*). Pada akhirnya, ketika pesan logistik nyata yang sangat kotor dan tidak terstruktur mendominasi, ketidakmampuan adaptasi tersebut akan memastikan bahwa model gagal berfungsi.

2.1.14. Data Augmentation

Metode augmentasi data teks telah terbukti secara ilmiah sangat efektif untuk mengatasi keterbatasan jumlah observasi dan variasi linguistik dalam sistem pemrosesan bahasa alami. "*Data augmentation* merupakan salah satu metode augmentasi data yang dapat digunakan untuk menangani kelas data yang tidak seimbang" [Azizah et al., 2023], menurut penelitian tentang penerapan augmentasi pada dataset berdomain khusus. Studi empiris lain pada dokumen berbahasa Indonesia juga menyatakan bahwa "augmentasi data dapat menjadi salah satu alternatif untuk pengembangan dataset pelatihan pada masalah data yang tidak seimbang" [Rahma et al., 2023]. Oleh karena itu, dapat dikatakan bahwa teknik augmentasi data adalah langkah komputasi yang penting untuk diterapkan untuk mencegah *overfitting* dan memastikan bahwa model *Deep Learning* memiliki kekuatan yang tinggi meskipun dilatih menggunakan sampel observasi lapangan yang terbatas.

2.1.15. Python sebagai Bahasa Pemrograman Utama untuk *Deep Learning*

Python telah menjadi standar utama untuk keseluruhan infrastruktur implementasi kecerdasan buatan dalam pengembangan arsitektur *Deep Learning*. Pilihan Python bergantung pada kemampuan untuk menggabungkan komputasi matematis tingkat tinggi menjadi sintaksis yang efisien dan mudah dipahami. "Python merupakan bahasa pemrograman tingkat tinggi yang paling banyak disukai untuk machine learning karena memungkinkan rancangan program komputasi dikelola secara efisien melalui ekosistem pustaka yang matang" [Oktaviana, 2026]. Ekosistem ini berfungsi sebagai motor penggerak

utama arsitektur. Di dalamnya, pustaka dasar seperti NumPy dan Pandas bertanggung jawab atas pra-pemrosesan vektor dan manipulasi kerangka data tabular, sementara kerangka kerja seperti PyTorch dan Hugging Face Transformers bertanggung jawab atas beban komputasi yang terkait dengan pelatihan model jaringan saraf. Dalam bidang linguistik, ekosistem ini sangat penting karena "pustaka open-source yang dibangun menggunakan bahasa pemrograman Python terbukti sangat andal untuk menangani masalah pemrosesan bahasa alami dengan cara yang efisien, salah satunya adalah Pengakuan Objek" [Yanti et al., 2021].

Tinjauan penelitian menunjukkan bahwa Python lebih dari sekadar alat untuk menulis logika algoritma. Itu adalah *platform* arsitektural yang mencakup fase ekstraksi data mentah, inferensi model linguistik tingkat lanjut (seperti IndoBERT), dan standardisasi akhir teks untuk pencatatan operasional logistik. Bahasa pemrograman ini sangat membantu menjembatani kesenjangan komputasi antara ketegasan filter penyempurna berbasis aturan dan kompleksitas jaringan saraf tiruan melalui keluwesan ekosistem pustakanya. Pada akhirnya, sinergi fungsional end-to-end ini memastikan bahwa sistem administrasi perusahaan dapat mengubah informasi komunikasi yang tidak terstruktur menjadi entitas data yang sah dan siap untuk diproses.

2.2. Penelitian Terkait

Untuk memperkuat landasan teoretis dan mengatur posisi penelitian ini, tinjauan terhadap penelitian sebelumnya telah dilakukan. Berdasarkan kajian literatur, domain ekstraksi multi-entitas (*NER*) memang telah banyak dibahas.

Namun, sebagian besar penelitian masih berkonsentrasi pada pemrosesan teks formal atau media sosial umum. Penerapan metode-metode tersebut secara spesifik di bidang komunikasi operasional logistik yang tidak terstruktur masih sangat terbatas dan belum dikaji secara komprehensif. Oleh karena itu, penelitian-penelitian berikut digunakan sebagai referensi dasar dan pembanding untuk mempertegas kebaruan (*novelty*) dari penelitian yang dilakukan.

NO	Penulis	Judul Penelitian	Ringkasan Penelitian	Metode	Research Gap
1.	[Ramadhan, 2026]	Indonesian <i>Online News Topics Classification using Word2Vec and K-Nearest Neighbor</i>	Fokus penelitian ini adalah untuk membagi dokumen teks berbahasa Indonesia ke dalam satu kategori topik tunggal. Data yang dikumpulkan berasal dari artikel berita online yang memiliki struktur bahasa yang jelas.	Menggunakan arsitektur pembelajaran mesin klasik, Word2Vec digunakan sebagai pengeks-traksi fitur (vektor statis) dan algoritma K-Nearest Neighbor (K-NN) digunakan sebagai pengklasifikasi-kelas.	Word2Vec efektif untuk teks formal, namun representasi vektor statisnya secara teoretis memiliki keterbatasan dalam mengakomodasi ekstraksi multi-entitas (<i>NER</i>) dan pencocokan relasi semantik. Kesenjangan konseptual ini di-jembatani oleh kapabilitas pemahaman konteks dinamis dari arsitektur <i>Transformer</i> (IndoBERT).
2.	[Supono, 2021]	Perbandingan Metode TF-ABS	Fokus penelitian ini adalah bagaimana	Ekstraksi fitur TF-	TF-IDF dan K-NN berhasil

		dan TF-IDF Pada Klasifikasi Teks Helpdesk Menggunakan K-Nearest Neighbor	otomatisasi dokumen keluhan berbahasa Indonesia (<i>helpdesk</i>) ke dalam kategori departemen tertentu. Text yang diproses berasal dari sistem pelaporan resmi dengan struktur kalimat yang kohesif.	IDF dan algoritma K-NN	mengklasifikasi dokumen formal, namun pada dasarnya tidak difokuskan untuk kebutuhan ekstraksi <i>multi-</i> entitas (<i>NER</i>). Keterbatasan arsitektural ini dijembatani secara efektif oleh pemahaman semantik dinamis pada <i>Transformer</i> (IndoBERT).
3.	[Adipradana et al., 2021]	Hoax analyzer for Indonesian news using RNNs with fasttext and glove embeddings	Fokus penelitian ini adalah menempatkan dokumen berita berbahasa Indonesia (valid, hoax, atau satire) ke dalam satu kategori berdasarkan tingkat kebenaran mereka.	Deep Learning (LSTM, GRU) dengan FastText dan GloVe.	Metode RNN dan FastText efektif untuk klasifikasi label tunggal, namun pemrosesan sekuensialnya secara teoretis berisiko kehilangan memori pada pesan yang panjang. Arsitektur ini juga belum dirancang untuk ekstraksi <i>multi-</i> entitas (<i>NER</i>).
4.	[Yanti et al., 2021]	Application of Named Entity Recognition via Twitter on SpaCy in Indonesian (Case Study: Power Failure in the Special Region of Yogyakarta)	Fokus penelitian adalah menemukan dan mengekstrak entitas lokasi (<i>NER</i>) dari teks keluhan masyarakat di Twitter berbahasa Indonesia.	Supervised Learning dengan Transition-Based Parser (SpaCy)	Arsitektur <i>Transition-Based Parser</i> (SpaCy) berfungsi baik untuk ekstraksi entitas dasar, namun ketiadaan model <i>pre-trained</i> resmi bahasa Indonesia membuatnya berisiko kesulitan memproses jargon logistik yang dinamis. Selain itu,

					model berbasis fitur lokal ini belum difokuskan untuk pencocokan relasi semantik.
5.	[Susanty, 2021]	Perbandingan <i>Pre-trained Word Embedding</i> dan <i>Embedding Layer</i> untuk <i>Named-Entity Recognition</i> Bahasa Indonesia	Penelitian ini berfokus pada ekstraksi multi-entitas (NER) bahasa Indonesia dengan membandingkan performa representasi kata (<i>Word2Vec</i> , <i>GloVe</i> , <i>FastText</i>) pada dataset formal.	Arsitektur BiLSTM dengan representasi kata GloVe	BiLSTM dan GloVe berkinerja baik pada teks formal, namun representasi vektor statisnya secara teoretis memiliki keterbatasan dalam menangkap ambiguitas makna pada pesan logistik. Selain itu, komputasi sekuensialnya berisiko mengalami <i>bottleneck</i> pada kalimat panjang.
6.	[Hasanah, 2021]	Pemantauan Perhatian Publik terhadap Pandemi COVID-19 melalui Klasifikasi Teks dengan <i>Deep Learning</i>	Penelitian ini berfokus pada pengklasifikasian teks Twitter ke dalam satu kategori topik utama (COVID-19 atau bukan) untuk memantau tren perhatian publik.	Deep Learning (LSTM) dengan Word Embedding FastText.	Kombinasi LSTM dan FastText sangat efektif untuk klasifikasi dokumen pendek berlabel tunggal. Namun, arsitektur ini tidak dirancang untuk ekstraksi multi-entitas (NER) secara paralel, dan komputasi sekuensialnya rentan mengalami <i>bottleneck</i> pada teks logistik yang panjang.

Berdasarkan table di atas dapat disimpulkan bahwa representasi vektor statis (seperti TF-IDF, Word2Vec, dan GloVe) dan komputasi sekuensial (seperti RNN, LSTM, dan BiLSTM) digunakan paling sering dalam penelitian pemrosesan bahasa alami (*NLP*) untuk bahasa Indonesia guna memenuhi kebutuhan klasifikasi dokumen formal dengan label tunggal. Secara teoritis, fitur arsitektur konvensional tersebut memiliki batasan logis jika diterapkan pada teks yang tidak terstruktur seperti untuk komunikasi operasional logistik pada WhatsApp. Sementara pemrosesan sekuensial berisiko mengalami kehilangan informasi dalam struktur kalimat yang panjang dan vektor statis akan menghadapi kesulitan untuk memahami ambiguitas makna. Selain itu, model klasifikasi sebelumnya secara struktural tidak memenuhi persyaratan ekstraksi *multi-entity* secara paralel (*NER*) dan pencocokan relasi semantik.


Kesenjangan teoretis tersebut dijawab melalui usulan implementasi arsitektur *Transformer*, secara spesifik menggunakan model *Fine-Tuning* IndoBERT. Keberadaan vektor dinamis (*contextualized embeddings*) pada arsitektur ini memungkinkannya untuk menangkap representasi makna kata yang berubah-ubah bergantung pada konteks kalimat secara utuh. Lebih lanjut, mekanisme *Self-Attention* dinilai sangat relevan secara arsitektural karena memberikan kapabilitas komputasi untuk memproses dan mengekstraksi seluruh elemen kompleksitas teks secara serentak, sehingga mengatasi keterbatasan pemrosesan sekuensial pada arsitektur konvensional.

BAB III

METODOLOGI PENELITIAN

3.1. Kerangka Pemikiran

Penelitian ini dirancang secara sistematis untuk mengatasi kendala operasional lapangan melalui pengembangan solusi berbasis kecerdasan buatan. Alur logika penyelesaian masalah ini dibagi ke dalam delapan tahapan utama sebagaimana terlihat pada bagan berikut:



1. Identifikasi Masalah

Tahap ini berfokus pada penemuan ketidakseimbangan kapasitas operasional PT. Rafay Logistik, di mana hanya dua administrator menangani entri data manual yang mencapai ribuan *field* setiap bulan. Kondisi ini lebih buruk ketika rencana ekspansi bisnis dikonfirmasi, yang diprediksi akan melampaui ambang batas kemampuan pemrosesan manual saat ini. Ini menimbulkan risiko penumpukan pekerjaan yang signifikan. Selain itu, ditemukan bahwa ada masalah dengan proses pencocokan dan entri ulang data susulan karena kebutuhan untuk melengkapi atau merevisi data parsial sebelumnya. Karena dilakukan secara manual di tengah tumpukan pesan WhatsApp yang tidak terstruktur, proses ini sangat lambat dan berpotensi menghambat kecepatan pembaruan data bisnis.

2. Studi Literatur & Tinjauan Pustaka

Tahap ini melakukan pengkajian mendalam terhadap landasan teoretis pemrosesan bahasa alami (*NLP*) berbasis *Deep Learning*. Fokus utama diarahkan pada arsitektur *Transformer* dan penggunaan model bahasa *fine-tuning* IndoBERT yang memiliki keunggulan dalam memahami konteks linguistik spesifik bahasa Indonesia, baik untuk tugas klasifikasi tingkat token maupun kalimat. Tinjauan pustaka juga mencakup eksplorasi metode *Named Entity Recognition* (NER) untuk ekstraksi informasi dan *Sequence-Pair Classification* untuk pengukuran kesamaan semantik. Pendekatan ini digunakan untuk membangun landasan komputasi yang kokoh dalam menyelesaikan masalah ambiguitas data logistik yang tidak terstruktur.

3. *Data Preparation & Preprocessing*

Persiapan data dimulai dengan mengumpulkan pesan mentah WhatsApp yang berfungsi dari grup operasional Pt. Rafay Logistik. Setelah itu, pesan diproses melalui beberapa tahap pemrosesan pra-ketat sebelum dikirimkan. Pembersihan derau (pembersihan data), normalisasi teks, dan validasi dan penyelarasan anotasi manual terhadap delapan kategori entitas logistik inti adalah tahapan dasar ini. Setelah teks mentah distandardisasi secara struktural, alur pembentukan korpus dibagi menjadi dua cabang yang berbeda untuk dataset tertentu, masing-masing disesuaikan dengan arsitektur pemodelan.

4. *Pelatihan Model Tahap 1 (Named Entity Recognition)*

Pelatihan tahap pertama difokuskan pada proses *fine-tuning* arsitektur model bahasa pra-latih indolem/indobert-base-uncased untuk mengeksekusi tugas *Token Classification*. Pemilihan varian uncased dari tim indolem ini diimplementasikan agar model komputasi dapat secara otomatis menormalkan variasi penulisan huruf kapital pada pesan WhatsApp yang tidak baku selama proses inferensi. Dalam alur pelatihannya, model menerima *input* berupa representasi token *WordPiece* yang telah dipetakan ke dalam skema pelabelan *BIO* (*Begin, Inside, Outside*). Transformasi arsitektural ini memungkinkan model untuk mempelajari batasan konteks secara spesifik guna mengekstraksi delapan entitas inti operasional logistik dengan kategori tanggal RO, tanggal muat, lokasi pick-up, lokasi tujuan, nomor plat, tipe truk, identitas pengemudi, dan kontak pengemudi.

5. Transformasi *Output NER*

Tahap ini berfungsi sebagai jembatan logika yang menghubungkan input Tahap 2 dengan hasil ekstraksi Tahap 1. Untuk menentukan apakah pesan tersebut merupakan entri baru atau instruksi susulan yang memerlukan pencocokan dengan data induk di Excel dan WhastApp, entitas yang berhasil diekstraksi dipisahkan berdasarkan niat pesanan (*intent*). Selanjutnya, data diubah menjadi format teks berpasangan. Tujuan dari proses sintesis adalah untuk membuat basis perbandingan antara pesan susulan (revisi atau penambahan) dengan data sebelumnya. Ini adalah komponen yang sangat penting agar proses *training* model tahap selanjutnya berjalan dengan baik.

6. Pelatihan Model Tahap 2 (*Semantic Similiarity/Sequence-Pair Classification*)

Untuk menjalankan tugas *Sequence-Pair Classification*, pelatihan tahap kedua menggunakan arsitektur model bahasa indobenchmark/indobert-base-p2. Pilihan varian p2 (*Phase 2*) dari repositori indobenchmark (IndoNLU) ini didasarkan pada keunggulannya yang telah melewati fase pelatihan tambahan dengan korpus yang lebih luas, yang memungkinkan representasi vektor yang lebih stabil dalam menangkap hubungan inferensi antar-kalimat. Secara teknis, model dilatih untuk memproses dua input teks sekaligus yakni pesan susulan dan data pesanan induk yang terpisah oleh token spesial. Kemudian, melalui *fine-tuning*, lapisan klasifikasi di atas token dioptimasi untuk secara otomatis mengidentifikasi tingkat relevansi

semantik antara kedua instruksi tanpa bergantung pada referensi yang jelas ke identitas pesanan. Implementasi teknis ini terutama berkonsentrasi pada dinamika pesan revisi dan pelengkapan data, yang seringkali diterima dalam format yang tidak konsisten dan dalam urutan acak.

7. Pengujian & Evaluasi

Metode evaluasi *Deep Learning* standar digunakan untuk mengukur kinerja sistem secara menyeluruh. Metode ini didasarkan pada perhitungan Matriks Konflik. Menghitung tingkat *True Positive (TP)*, *False Positive (FP)*, dan *False Negative (FN)* untuk setiap prediksi kelas model adalah fokus dari pengukuran. Sistem menderivasi nilai akhir untuk *Precision*, *Recall*, dan *F1-Score* dari komponen dasar tersebut untuk menyeimbangkan ketepatan prediksi dan kemampuan deteksi secara keseluruhan. Untuk memastikan bahwa kinerja model tervalidasi secara proporsional terhadap distribusi kelas logistik saat ini, evaluasi ini juga menggunakan metrik *support* untuk menghitung jumlah representasi yang sebenarnya dari setiap entitas pada dataset yang diuji.

8. Antarmuka Pengujian

Tahap akhir difokuskan pada pengembangan antarmuka pengujian (*testing environment*) berbasis web menggunakan *framework* Streamlit yang diintegrasikan dengan beberapa pustaka pendukung dari ekosistem bahasa pemrograman Python. Purwarupa ini dibangun murni sebagai media visualisasi interaktif dan bukan ditujukan sebagai perangkat lunak operasional akhir siap pakai bagi perusahaan. Keberadaan antarmuka ini

dirancang secara khusus untuk memfasilitasi proses demonstrasi, di mana dapat menguji model dengan memasukkan masukan teks secara langsung, lalu memantau keluaran sistem baik ketepatan ekstraksi *field* maupun akurasi pencocokan data secara *real-time* dan transparan.

3.1.1. Teknik Pengumpulan Data

Penelitian ini berfokus pada pengumpulan data tentang lingkungan operasional PT. Rafay Logistik dan alur kerja manual dan bahan baku dataset. Dua jenis data utama dihasilkan sebagai hasil dari proses akuisisi ini yaitu data rekapitulasi akhir dalam format Excel sebagai target luaran (*ground truth*) dari Oktober 2025 hingga Maret 2026 dan log pesan mentah WhatsApp dari bulan Maret sebagai data masukan awal, yang kemudian diperluas untuk memenuhi kebutuhan pelatihan pemodelan bahasa. Pengumpulan data dilakukan melalui wawancara, observasi lapangan, dan studi pustaka untuk memenuhi kebutuhan dataset.

3.1.2. Observasi

Observasi dilaksanakan melalui pengamatan langsung terhadap alur kerja (*workflow*) harian yang dieksekusi oleh dua staf administrator PT. Rafay Logistik. Fokus pengamatan diarahkan pada tahapan pemrosesan instruksi mentah dari grup WhatsApp yang harus diekstraksi dan dipindahkan secara manual ke dalam format terstruktur pada file pencatatan Excel. Melalui proses pengamatan faktual ini, peneliti berhasil memetakan dua risiko operasional utama yang mengancam stabilitas administrasi perusahaan. Risiko pertama adalah ancaman penumpukan pekerjaan akibat ketidakseimbangan antara

tingginya volume pesanan baru dengan kapasitas entri manual. Risiko kedua adalah kerentanan terhadap keterlambatan dan kesalahan pembaruan informasi (*human error*), yang dipicu oleh tingginya kompleksitas saat administrator harus mencari dan memadankan pesan susulan (*refill/revisi*) dengan data historis secara manual. Identifikasi atas risiko-risiko ini menjadi landasan empiris dari lapangan mengenai mendesaknya kebutuhan intervensi sistem otomasi.

3.1.3. Wawancara

Ada dua belah pihak yang diwawancarai secara langsung yakni staf manajemen dan pemilik PT. Rafay Logistik. Fokus wawancara dengan administrator adalah untuk mendapatkan pemahaman tentang standar teknis yang mereka gunakan untuk mengekstraksi dan membedakan pesanan baru, revisi, dan pelengkapan data. Untuk sementara, pemilik perusahaan diwawancarai dengan tujuan menyesuaikan aturan operasional dan memproses permohonan izin akses arsip internal. Pada tahap ini, peneliti secara resmi memperoleh bahan penelitian, yaitu rekapitulasi target Excel (Oktober 2025–Maret 2026) dan log pesan mentah WhatsApp yang beroperasi (khusus untuk bulan Maret), yang keterbatasan waktunya akan diatasi melalui metode ekspansi data.

3.1.4. Studi Pustaka

Berbagai publikasi dan jurnal ilmiah yang membahas topik penelitian ini diselidiki. Fokus penelusuran referensi adalah penggunaan arsitektur Transformer. Ini terutama mencakup penggunaan varian model

indolem/indobert-base-uncased untuk tugas ekstraksi entitas (*Named Entity Recognition*) dan indobenchmark/indobert-base-p2 untuk tugas pencocokan pasangan urutan. Studi pustaka ini juga membantu peneliti membuat metode augmentasi data teks, membuat rencana anotasi BIO, dan menemukan metrik evaluasi kinerja model yang ideal untuk diterapkan pada skenario otomasi administrasi logistik.

3.2. Metode Ai Yang Gunakan

Sistem otomasi dalam penelitian ini dibangun menggunakan pendekatan *Natural Language Processing* (NLP) guna mengurai kompleksitas teks instruksi operasional logistik. Mengingat data masukan bersumber dari pesan mentah WhatsApp yang sangat tidak terstruktur dan dinamis, pendekatan sistem manual maupun *rule-based* (berbasis aturan statis) terbukti tidak lagi memadai. Oleh karena itu, penelitian ini merancang sebuah *pipeline* komputasi berbasis *Deep Learning* yang mampu memahami konteks bahasa manusia secara komprehensif, mulai dari proses ekstraksi entitas pesanan hingga tahapan resolusi ambiguitas pada data susulan.

3.2.1. Arsitektur IndoBERT

Arsitektur Deep Learning Transformer, khususnya turunan model BERT (*Bidirectional Encoder Representations from Transformers*), adalah dasar untuk pengembangan sistem otomasi dalam penelitian ini. Algoritma BERT memiliki keunggulan komputasi dalam membaca konteks kalimat secara dua arah (bidireksional), yang memungkinkannya dengan sangat akurat mengurai makna struktural teks. Penelitian ini menggunakan IndoBERT, versi adaptasi

BERT yang telah dilatih khusus menggunakan korpus teks bahasa Indonesia untuk menangani instruksi operasional logistik. Pemodelan IndoBERT ini dibagi menjadi dua tahapan tugas khusus dengan varian model yang dioptimasi (*fine-tuning*) sesuai dengan fungsinya untuk menyelesaikan masalah penumpukan data dari pesan WhatsApp yang tidak terstruktur:

1. *Named Entity Recognition* (NER) Berbasis indolem/indobert-base-uncased

Tahap komputasi pertama difokuskan pada ekstraksi atribut pesanan menggunakan algoritma *Token Classification*. Pada tahap ini, penelitian menggunakan spesifikasi model indolem/indobert-base-uncased. Pemilihan varian *uncased* diterapkan secara sengaja agar algoritma mengabaikan sensitivitas huruf kapital, sehingga variasi penulisan teks WhatsApp yang tidak baku dapat dinormalkan secara langsung. Secara teknis, teks masukan dipecah melalui mekanisme tokenisasi *WordPiece*, kemudian model dilatih untuk mengklasifikasikan setiap token ke dalam 8 label berbasis skema *BIO* (*Begin, Inside, Outside*). Hasil komputasi ini memungkinkan sistem untuk menarik delapan entitas logistik inti (seperti nama, rute, dan jenis barang) secara otomatis, menggantikan proses pemindahan data manual oleh staf administrator.


2. *Sequence-Pair Classification* Berbasis indobenchmark/indobert-base-p2

Tahap komputasi kedua ditujukan untuk mengotomatisasi pencocokan data susulan (*refill* atau revisi) menggunakan algoritma *Sequence-Pair Classification*. Tahap ini mengimplementasikan arsitektur indobenchmark/indobert-base-p2 yang terbukti stabil dalam memetakan

relasi makna antar-kalimat. Secara operasional, algoritma ini memproses dua masukan teks secara bersamaan yakni teks pesanan induk dan teks pesan susulan yang dihubungkan menggunakan token pembatas . Model kemudian mengalkulasi representasi vektor dari token klasifikasi pada lapisan terakhir untuk menentukan probabilitas kesesuaian semantik di antara kedua pesan tersebut. Pendekatan algoritmik ini menjadi solusi agar sistem dapat memadankan instruksi susulan yang teracak ke baris data yang tepat, meskipun pesan tersebut sama sekali tidak memuat nomor referensi identitas secara eksplisit.

3.3. Model Pengembangan Sistem

Penelitian ini mengadopsi metodologi *CRISP-DM* (*Cross-Industry Standard Process for Data Mining*) sebagai kerangka kerja utama dalam pengembangan sistem otomasi ekstraksi informasi. *CRISP-DM* dipilih karena menawarkan alur kerja iteratif yang sangat terstruktur, berpusat pada siklus hidup data, dan telah menjadi standar industri paling andal untuk mengawal proyek berbasis *Deep Learning* dan *Natural Language Processing* (NLP). Metodologi ini memastikan bahwa proses spesialisasi (*fine-tuning*) arsitektur IndoBERT tidak sekadar berfokus pada keberhasilan metrik komputasional secara matematis, melainkan terbukti relevan dan aplikatif dalam memecahkan masalah operasional penumpukan data yang faktual di PT. Rafay Logistik.



Siklus pengembangan *CRISP-DM* terdiri dari enam tahapan yang saling berkesinambungan, yaitu:

1. *Business Understanding*

Langkah pertama berfokus pada identifikasi potensi hambatan operasional di lapangan. Peneliti membedah kendala faktual terkait tingginya ketergantungan pada pemrosesan manual untuk mengurai teks pesanan dan mencocokkan data susulan dari pesan WhatsApp yang tidak terstruktur menjadi output terstruktur dalam format Excel, di mana hal ini memendam risiko penumpukan pekerjaan seiring dengan proyeksi ekspansi bisnis ke depan. Tujuan utama pada fase ini menetapkan bahwa solusi yang

ditawarkan berupa sistem otomasi ekstraksi informasi dan pencocokan relasi data yang berlandaskan pada arsitektur *Deep Learning*.

2. *Data Understanding*

Setelah landasan proyek disepakati, peneliti mulai mengumpulkan kumpulan data (dataset) berupa rekapitulasi target data dari Excel dan log pesan mentah dari grup WhatsApp operasional. Kumpulan teks ini mencakup instruksi pesanan baru, revisi, hingga pelengkapan data (*refill*). Pada tahap ini, peneliti mengeksplorasi kondisi mentah dari teks tersebut, menyeleksi tingkat derau (*noise*), mengamati ketidakbakuan bahasa dan singkatan, serta memastikan pangkalan data memiliki distribusi kelas entitas yang memadai agar mesin tidak mengalami bias saat proses belajar nanti.

3. *Data Preparation*

Fase ini adalah tahap prakomputasi yang krusial sebelum data masuk ke dalam mesin. Teks mentah dari tahap sebelumnya belum bisa langsung dibaca oleh algoritma. Peneliti melakukan pembersihan data, normalisasi teks, dan augmentasi untuk memperkaya variasi pola linguistik guna mengatasi keterbatasan rentang waktu data log. Khusus untuk kebutuhan pelatihan, peneliti wajib melakukan anotasi manual dengan memetakan token ke dalam 15 *NER* tags (BIO format dari 7 entity types) pada platform Label-Studio. Anotasi ini berfungsi sebagai kunci jawaban (*ground truth*) yang akan diajarkan kepada arsitektur mesin IndoBERT.

4. *Modeling*

Setelah itu, data teks yang sudah dibersihkan dan dianotasi dimasukkan ke dalam tahap pelatihan algoritma. Fase ini mengoptimalkan secara terpisah arsitektur komputasi *Deep Learning* berdasarkan fungsinya. Pertama, peneliti menginstruksikan model *fine-tuning* indolem/indobert-base-uncased untuk melakukan ekstraksi entitas yang dikenal sebagai Pengenalan Entitas (*Named Entity Recognition*). Ini memungkinkan sistem untuk mengatasi batasan token dan menarik delapan atribut logistik inti. Selanjutnya, data tambahan dikirim untuk melatih jaringan indobenchmark/indobert-base-p2. Salah satu tugas jaringan *Transformer* adalah membedah relasi semantik. Ini dilakukan untuk menentukan tingkat kesesuaian yang tepat antara data pesanan induk dan pesan susulan.

5. *Evaluation*

Sebelum algoritma dinyatakan siap pakai, kinerjanya diuji secara ketat untuk mencegah kesalahan pencatatan operasional. Peneliti membandingkan hasil tebakan mesin dengan anotasi manual menggunakan berbagai metrik matematis turunan matriks kebingungan (*Confusion Matrix*), seperti presisi (*Precision*), kemampuan pelacakan ulang (*Recall*), hingga skor keseimbangan (*F1-Score*). Pada tahap ini, peneliti juga memvalidasi ketepatan prediksi model pada setiap kelas entitas untuk membuktikan bahwa mesin sungguh mendeteksi konteks kata yang tepat. Jika akurasi ekstraksi mesin dinilai masih rendah, proses akan berputar kembali ke tahap persiapan data atau pemodelan untuk menyetel ulang parameter.

6. *Deployment*

Dalam ruang lingkup penelitian ini, tahap penyebaran direalisasikan bukan sebagai peluncuran perangkat lunak skala produksi, melainkan sebagai wujud serah terima purwarupa visualisasi interaktif. Model IndoBERT yang telah dievaluasi dikemas ke dalam antarmuka web menggunakan kerangka kerja Streamlit. Implementasi ini difungsikan murni sebagai lingkungan pengujian (*testing environment*) terintegrasi yang telah digunakan peneliti untuk memvisualisasikan hasil komputasi secara iteratif. Melalui antarmuka ini, kinerja algoritma dapat didemonstrasikan secara nyata di luar kode pemrograman mentah, memungkinkan penguji atau administrator untuk menyimulasikan masukan teks pesan operasional dan melihat visualisasi ekstraksi entitas beserta rekomendasi pencocokan datanya secara langsung

BAB III

HASIL DAN PEMBAHASAN

4.1. Tinjauan Perusahaan

4.1.1. Profil Perusahaan

4.1.2. Struktur Perusahaan

4.2. Analisis Kebutuhan Sistem

Bagian ini membahas kondisi sistem administrasi logistik sebelum pengembangan, serta persyaratan yang harus dipenuhi oleh sistem ekstraksi informasi dan pencocokan data berbasis *Deep Learning* yang dirancang dalam penelitian ini. Analisis dilakukan untuk memastikan bahwa arsitektur sistem ekstraksi yang dibangun tidak hanya berhasil secara teknis komputasional, tetapi juga relevan untuk memitigasi risiko skalabilitas operasional PT. Rafay Logistik.

4.2.1. Analisis Sistem Saat Ini

Observasi lapangan di PT. Rafay Logistik menunjukkan bahwa proses ekstraksi dan pencatatan instruksi operasional sepenuhnya bergantung pada tangan manusia. Sumber data utama berasal dari komunikasi berbasis teks di grup WhatsApp yang dirancang khusus untuk tujuan operasional. Membaca, mengurai, dan menyusunnya menjadi luaran terstruktur dalam format rekapitulasi Excel bulanan yang mencakup delapan atribut entitas yang diperlukan adalah tanggung jawab administrator.

Untuk memahami kompleksitas beban kognitif administrator, berikut adalah representasi faktual dari format pesan mentah yang diolah setiap harinya:

1. Pesanan Baru *Multi-Unit* dengan Data Parsial Berikut:

Tabel 4.2

```
[05.31, 7/3/2026] Akbar Rafay: REQUEST ORDER ONCALL 03 maret 2026:  
5 UNIT WB/50 CBM  
Lokasi : ARGOPANTES  
Waktu loading : Segera  
Rute/tujuan : CGK - PKU  
driver : Soni Rahmat  
Nopol : BM 8142 RY  
  
No hp : 082282001964  
Waktu loading : 15;00  
Rute/tujuan : CGK - PKU  
driver :  
Nopol :  
No hp :  
  
Waktu loading : 20:00  
Rute/tujuan : CGK - PKU  
driver :  
Nopol :  
No hp :
```

2. Contoh Kasus 2: Data Susulan (Revisi dan *Refill*)

4.2.2. Analisis Kebutuhan Fungsional

4.2.3. Analisis Kebutuhan Non Fungsional

4.3. Perancangan dan Implementasi Sistem

4.3.1. Deskripsi Sistem

4.3.2. Tahapan Pengembangan Model AI

4.3.3. Implementasi Perangkat Lunak

4.4. Pengujian Sistem

4.4.1. Pengujian Fungsional

4.4.2. Uji Coba Pengguna

DAFTAR PUSTAKA

Adipradana R, Nayoga BP, Suryadi R, Suhartono D. 2021. Hoax analyzer for Indonesian news using RNNs with fasttext and glove embeddings. 10: 2130–2136.

Adrianto LB. 2021. Implementasi Deep Learning untuk Sistem Keamanan Data Pribadi Menggunakan Pengenalan Wajah dengan Metode Eigenface Berbasis Android. 5.

Annisa ZA, Perdana RS, Adikara PP, Brawijaya U, Korespondensi P. 2024. KOMBINASI INTENT CLASSIFICATION DAN NAMED ENTITY RECOGNITION PADA DATA BERBAHASA INDONESIA DENGAN METODE DUAL INTENT AND COMBINING INTENT CLASSIFICATION AND NAMED ENTITY RECOGNITION ON. 11: 1017–1024.

Awalina A, Bachtiar FA, Utaminingrum F, Brawijaya U, Korespondensi P. 2022. PERBANDINGAN PRETRAINED MODEL TRANSFORMER PADA DETEKSI COMPARISON OF PRETRAINED TRANSFORMER MODELS ON SPAM REVIEW. 9.

Azizah AN, Falach M, Wisma I, Prastya D, Purwitasari D, Korespondensi P, Daring KK. 2023. EASY DATA AUGMENTATION UNTUK DATA YANG IMBALANCE PADA EASY DATA AUGMENTATION FOR IMBALANCED DATA OF ONLINE HEALTH. 10.

Dan K, Dengan A, An A-QUR, Hadits DAN. 2025. ANALISIS BERT-CNN UNTUK KLASIFIKASI MULTI-LABEL DISKUSI BERT-CNN ANALYSIS FOR MULTI-LABEL CLASSIFICATION OF RELIGIOUS DISCUSSIONS AND THEIR ASSOCIATION WITH THE QUR ' AN AND HADITH. 12: 1415–1424.

Dyah S, Umbara N, Eviyanti A. 2026. EKSTRAKSI INFORMASI DARI DOKUMEN CV MENGGUNAKAN PENDEKATAN

HYBRID NATURAL LANGUAGE PROCESSING DAN RULE-BASED. 10: 1885–1890.

Ezer E, Marpaung O, Tarigan M. 2026. PERBANDINGAN MODEL INDOBERT DAN INDONESIAN ROBERTA BASE DALAM ANALISIS SENTIMEN PENGGUNA TWITTER TERHADAP TIMNAS INDONESIA DI KUALIFIKASI PIALA DUNIA 2026. 10: 30–37.

Fathur M, Khairul R, Perdana RS, Brawijaya U, Korespondensi P. 2024. ARCHITECTURE OF AUTOMATIC CONVERSATION SYSTEM IN INDONESIAN LANGUAGE WITH NORMALIZATION OF INFORMAL LANGUAGE INTO. 11: 1009–1016.

Han X, Zhang Z, Ding N, Gu Y, Liu X, Huo Y, Qiu J, Yao Y, Zhang A, Zhang L, Han W, Huang M, Jin Q, Lan Y, Liu Y, Liu Z, Lu Z, Qiu X, Song R, Tang J, Wen J, Yuan J, Zhao WX, Zhu J. 2021. Pre-Trained Models: Past, Present and Future.

Hanif IA, Tjitrajardja E, Naufal RB, Rahadiani L. 2026. Automated Assignment of Community Reports With Early Fusion Multimodal Transformer. 1: 1–9.

Hasanah NA. 2021. Pemantauan Perhatian Publik terhadap Pandemi COVID-19 melalui Klasifikasi Teks dengan Deep Learning. 1: 193–202.

Hasmin E, Studi P, Informatika T, Makassar UD. 2024. Deteksi penyakit rumput laut dengan residual neural network. 7: 637–646.

Ignasius D, Dewi IN, Bernadette M, Norman C, Sani RR. 2025. Medical Named Entity Recognition from Indonesian Health-News using BiLSTM-CRF with Static and Contextual Embeddings. 9: 2974–2984.

Ishak R. 2026. Optimasi Embedding IndoBERT dengan Ditto Whitening untuk Pengukuran Kesamaan Judul Penelitian

Optimizing of IndoBERT Embedding with Ditto Whitening for Measuring Research Title Similarity. 8.

Jiang H, Zhang D, Cao T, Yin B, Zhao T. 2021. Named Entity Recognition with Small Strongly Labeled and Large Weakly Labeled Data. 1775–1789.

Kalyan KS, Rajasekharan A, Sangeetha S. 2021. AMMUS : A Survey of Transformer-based Pretrained Models in Natural Language Processing. 1–42.

Kenton MC, Kristina L, Devlin J. 2019. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding.

Kunilovskaya M. 2021. Text Preprocessing and its Implications in a Digital Humanities Project. 85–93.

Lin T, Wang Y, Liu X, Qiu X. 2021. A Survey of Transformers. 1.

Maharani U, Irawan MD, Islam U, Sumatera N. 2025. Sistem informasi monitoring petugas bidang lalu lintas menggunakan metode havershine formula berbasis android. 9: 47–62.

Oktaviana UN. 2026. Klasifikasi Penyakit Padi berdasarkan Citra Daun Menggunakan Model. 5: 9–11.

Pradani KA, Suadaa LH, Timur J, Korespondensi P. 2023. AUTOMATED ESSAY SCORING MENGGUNAKAN SEMANTIC TEXTUAL AUTOMATED ESSAY SCORING USING TRANSFORMER-BASED SEMANTIC. 10: 1177–1184.

Prasetyo B, Nur M. 2024. A Novel Fusion of Machine Learning Methods for Enhancing Named Entity Recognition in Indonesian Language Text. 1–10.

Rahma IA, Suadaa LH, Timur J, Korespondensi P. 2023. PENERAPAN TEXT AUGMENTATION UNTUK

MENGATASI DATA YANG TIDAK SEIMBANG PADA
KLASIFIKASI TEKS BERBAHASA INDONESIA STUDI
KASUS : DETEKSI JUDUL CLICKBAIT DAN KOMENTAR
HATE SPEECH APPLICATION OF TEXT AUGMENTATION
TO HANDLING IMBALANCED DATA PROBLEM IN
INDONESIAN TEXT CLASSIFICATION CASE STUDY :
CLICKBAIT HEADLINE AND HATE SPEECH COMMENT.
10: 1329–1340.

Ramadhan NG. 2026. JURNAL RESTI Indonesian Online News
Topics Classification using Word2Vec and. 7–10.

Sepriadi H, Sekarsari CR, Iriany A, Achmad A, Fernandes R,
Brawijaya U, Korespondensi P, Society C, Allocation LD,
Modeling T. 2025. KOMBINASI ANALISIS BIBLIOMETRIK
DENGAN LATENT DIRICHLET COMBINATION OF
BIBLIOMETRIC ANALYSIS WITH LATENT DIRICHLET
ALLOCATION AS TOPIC MODELING OF CASHLESS
SOCIETY BEHAVIOR. 12: 331–338.

Sharou K Al, Li Z, Specia L. 2021. Towards a Better Understanding of
Noise in Natural Language Processing. 53–62.

Stanford University. 2023. AI Index Report 2023: Measuring trends in
Artificial Intelligence. AI Index Rep.: 1–386.

Supono RA. 2021. Perbandingan Metode TF-ABS dan TF-IDF Pada
Klasifikasi Teks Helpdesk Menggunakan K-Nearest Neighbor. 5:
911–918.

Susanty M. 2021. Perbandingan Pre-trained Word Embedding dan
Embedding Layer untuk Named-Entity Recognition Bahasa
Indonesia. 14: 247–257.

Syazal MR, Yulianti E. 2025. Classification of Economic Activities in
Indonesia Using IndoBERT Language Model. 2: 155–165.

Tandi TY. 2025. Incorporation of IndoBERT and Machine Learning

- Features to Improve the Performance of Indonesian Textual Entailment Recognition. 11: 173–186.
- Tharwat A. 2026. Classification assessment methods. 17: 168–192.
- Vaswani A. 2023. Attention Is All You Need.
- Wesley R, Gunawan R. 2024. LITERATUR REVIEW : METODE DEEP LEARNING UNTUK ANALISIS TEKS. 8: 11020–11023.
- Yanti RM, Santoso I, Suadaa LH. 2021. Application of Named Entity Recognition via Twitter on SpaCy in Indonesian (Case Study : Power Failure in the Special Region of Yogyakarta). 4: 76–86.
- Zhang Y, Meng F, Chen Y. 2021. Target-Oriented Fine-tuning for Zero-Resource Named Entity Recognition. 1603–1615.